Projet : Développez une preuve de concept

Antoine Maby - 28/12/2021

Problématique

Le domaine du machine learning, et plus généralement de la data science, évolue très rapidement

Il est important de développer l'habitude de se tenir au courant des avancées dans ce domaine en effectuant une veille thématique

Il est important de monter rapidement en compétence sur une nouvelle thématique, en sachant effectuer une recherche et mettre en pratique un nouvel algorithme de façon autonome

Problématique

Déroulement du problème :

- Trouver un algorithme
- Choisir un Dataset
- Trouver une bibliographie
- Choisir une Baseline
- Implémenter la nouvelle méthode
- Comparer les résultats

Choix du problème

- Le projet précédent portait sur la classification d'images

- Les algorithmes nécessitent une grande quantité d'images étiquetées

- Existe-t'il une solution à ce problème?

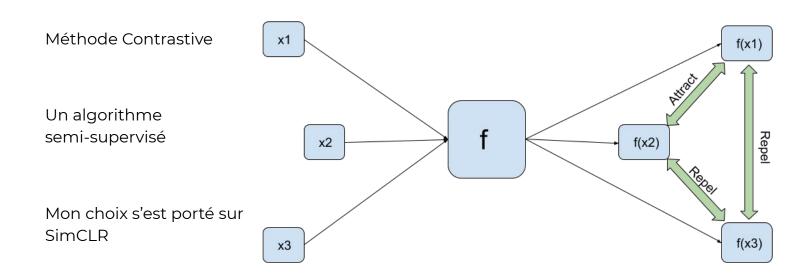
Self-supervised Learning

- Rechercher dans des données non étiquetées des groupes d'exemples partageant des caractéristiques communes

- Chacune d'entre elles est fournie, en entrée, dans sa forme originale et une version transformée

- Les plus performantes sont : les Transformer et les méthodes Contrastives

Self-supervised Learning

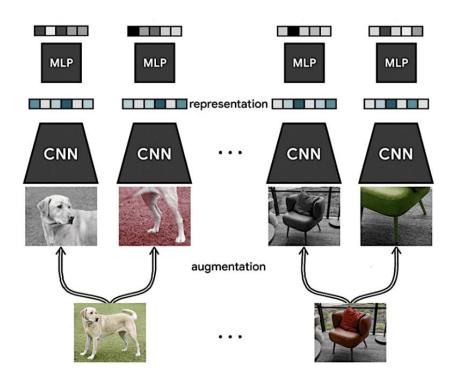


SimCLR

- Augmentation

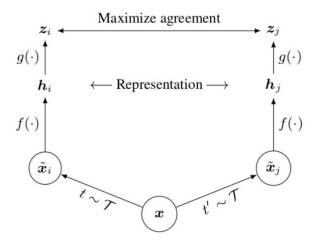
- Création de représentation

- MLP



SimCLR

```
Algorithm 1 SimCLR's main learning algorithm.
input: batch size N, constant \tau, structure of f, g, \mathcal{T}.
for sampled minibatch \{x_k\}_{k=1}^N do
   for all k \in \{1, \dots, N\} do
      draw two augmentation functions t \sim T, t' \sim T
       # the first augmentation
       \tilde{\boldsymbol{x}}_{2k-1} = t(\boldsymbol{x}_k)
      \boldsymbol{h}_{2k-1} = f(\tilde{\boldsymbol{x}}_{2k-1})
                                                           # representation
       z_{2k-1} = g(h_{2k-1})
                                                                 # projection
       # the second augmentation
       \tilde{\boldsymbol{x}}_{2k} = t'(\boldsymbol{x}_k)
      h_{2k} = f(\tilde{x}_{2k})
                                                           # representation
       \boldsymbol{z}_{2k} = g(\boldsymbol{h}_{2k})
                                                                 # projection
    end for
    for all i \in \{1, \dots, 2N\} and j \in \{1, \dots, 2N\} do
       s_{i,j} = \mathbf{z}_i^{\top} \mathbf{z}_j / (\|\mathbf{z}_i\| \|\mathbf{z}_j\|) # pairwise similarity
   end for
   define \ell(i,j) as \ell(i,j) = -\log \frac{\exp(s_{i,j}/\tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k\neq i]} \exp(s_{i,k}/\tau)}
    \mathcal{L} = \frac{1}{2N} \sum_{k=1}^{N} \left[ \ell(2k-1, 2k) + \ell(2k, 2k-1) \right]
   update networks f and g to minimize \mathcal{L}
end for
return encoder network f(\cdot), and throw away g(\cdot)
```



Les données

- Base de données : Stanford Dogs Dataset

- Plus de 20 000 images de chiens

- 120 races différentes





Les données



	Pretrain	Train	Test
Nombre de photos	12000	1716	6864



Baseline

- Inceptionv3

- Entraînement seulement sur le Classifier

- Classifier composé de Trois couches denses et d'un Drop Out

Baseline

- Résultats obtenus après entraînement sur le Train, performance sur le Test

	Inceptionv3
Accuracy Top 1	4.1

- Pré-entraînement grâce au routine fourni sur <u>https://github.com/google-research/simclr</u>

- Finetune sur les données de Train

- Tests des performances sur le Test

- Résultats obtenus

	InceptionV3	SimCLRv1
Accuracy Top 1	4.1	6,8

- SimCLR est déjà plus performant que notre Baseline

- Les performances restent limitées

- Testons le modèle fourni par les auteurs en finetune sur les données

- Pré-entraînement des auteurs sur ImageNet

- Finetune sur les données de Train

- Tests des performances sur le Test

- Résultats obtenus

	Inceptionv3	SimCLRv1	SimCLRv2
Accuracy Top 1	4.1	6.8	62,5

- SimCLR est bien plus performant que notre Baseline et notre SimCLR

Les performances s'approchent des résultats obtenus sur le projet 6

- Ceci nous donne une borne inférieure des performances possibles

Conclusion

- SimCLR répond à notre problématique en ayant de bonnes performances
- Des améliorations sont possibles :
 - pré-entraînement sur plus grand nombre données
 - Meilleurs paramétrages du pré-entraînement
- Il est peut être possible de dépasser les performances obtenu lors du projet 6

Merci pour votre attention